Gemini Robotics-ER を用いた自然言語指示による卓上片付けタスクの実現

Vision-Language Model による意味理解と深度画像に基づく幾何処理を組み合わせた閉ループ型マニピュレーション

アカウント	kissyossy
動画	https://youtu.be/RmRP9BtQHjI
コード	https://github.com/kissyossy6/PhisicalAI
ベースとしたサンプル	「Gemini Robotics-ER 1.6 を試す」（難易度: 中級）[1]

1. 背景と目的

人が他者に片付けを依頼する場合、対象物の座標や置き場所を逐一指定することはない。「食べ物は皿に」といった抽象的な指示から、 どの物体が食べ物に該当するか、それがどこにあり、皿のどこに置けば既存の物と干渉しないかを、依頼された側が自ら判断している。 ロボットが家庭やオフィスで実用的に働くためには、このような意味的な判断と、物体を確実に把持・運搬するための幾何学的な精度とを両立させる必要がある。

ベースとしたサンプル [1] は、ロボティクス向けの Vision-Language Model（VLM）である Gemini Robotics-ER に画像を入力し、 2D ポインティング、物体検出、軌道生成、空間推論、タスク分解の各機能を試すものであり、出力を画像上で可視化する段階で完結している。 本課題ではこれを発展させ、VLM の出力を物理シミュレータ上のロボットアームの動作に接続し、さらに動作結果の確認と再計画を含む閉ループのシステムとして構成した。 目的は、自然言語による一つの指示のみを入力として、ロボットが卓上の物体を分類し、指定された容器へ最後まで片付けきることである。

2. タスク設定

MuJoCo [2] 上に、7 自由度アーム Franka Emika Panda（MuJoCo Menagerie [3] のモデル）と、木製の作業台を配置した。 作業台上には果物 3 種（りんご、オレンジ、レモン）と積み木 3 個（赤・青・緑の立方体）を、乱数シードに基づいて位置と向きをランダムに配置する。 容器として白い皿とオレンジ色のおもちゃ箱を置く。ロボットへの入力は次の指示文のみである。

「机の上を片付けて。食べ物はお皿に、おもちゃは箱にしまってね。」

ロボットはシミュレータ内部の物体座標を一切参照せず、作業台の正面上方に固定した 1 台の RGB-D カメラ（800×600 画素、垂直画角 58°）の画像のみから行動を決定する。 シミュレータの真値は、実行後の評価にのみ用いた。また、実行の途中で片付け済みの物体を一つ作業台に戻す外乱を加え、環境の変化に対する頑健性も確認した。

3. システム構成

3.1 全体の流れ

システムは、VLM が担う意味的な判断と、深度画像および運動学に基づく幾何的な処理とに役割を分けている（表 1）。処理の流れは以下のとおりである。

(1) 計画　　画像と指示文から、物体の一覧・分類・行き先・実行順序を生成する　　[plan]
(2) 各ステップについて、以下を繰り返す
　(a) 観測　　画像を取得し、VLM に次の 3 点を 1 回の問い合わせで尋ねる　　[locate]
　　・直前のステップの物体が容器に収まったか（成功判定）
　　・次に把持する物体の画像上の位置（2D ポインティング）
　　・容器内で既存の物体や縁と干渉しない配置位置（空間推論）
　(b) 位置推定 2D 点を深度画像で 3 次元に逆投影し、周辺の点群から把持位置と向きを補正する
　(c) 動作　　逆運動学による直線軌道で、把持・運搬・配置を行う
(3) 全ステップ終了後に再度 (1) を行い、未処理の物体があれば (2) を繰り返す

機能	担当
指示の解釈、物体の分類、行き先と実行順序の決定	Gemini Robotics-ER（plan）
物体の画像上の位置、容器内の配置位置、直前の動作の成否	Gemini Robotics-ER（locate）
把持位置の 3 次元座標と把持方向	深度画像に基づく幾何処理
関節軌道の生成	減衰最小二乗法による逆運動学
把持失敗の検出	グリッパの開き幅

表 1　機能の分担

3.2 Vision-Language Model による計画と観測

VLM には gemini-robotics-er-2-preview [4] を用いた。サンプル [1] で用いられている gemini-robotics-er-1.6-preview は、 2026 年 10 月時点で API の提供が終了していたため、後継モデルに置き換えた。プロンプトの形式はサンプルに倣い、画像上の点は [y, x] を 0〜1000 に正規化した値で出力させている。

計画（plan）では、作業台上の各物体について、ラベル、画像上の位置、分類、行き先、判断理由を JSON 形式で出力させる。 推論の質を高めるため、思考トークンの上限（thinking budget）を 2048 とした。観測（locate）は各ステップの直前に必ず実行し、計画時の座標は再利用しない。 これにより、前の動作で物体がずれた場合や、人が物体を動かした場合にも、最新の観測に基づいて動作できる。

当初は、物体の位置、配置位置、成功判定をそれぞれ別の問い合わせとしていたが、1 回の実行に約 25 回の API 呼び出しが必要となり、 無料枠の上限（毎分 5 回、1 日 20 回）では完走できなかった。そこで、直前の動作の成功判定と次の物体の観測とを 1 回の問い合わせに統合し、 最後のステップの成功判定は終了時の再計画で兼ねる構成とした。その結果、外乱を含む 1 回の実行に要する呼び出しは 10 回となった。

3.3 深度画像に基づく把持位置の推定

VLM が出力する 2D 点は、どの物体を指しているかを特定するには十分な精度を持つ。一方で、斜め上方からの画像では点が物体の手前の側面に置かれることがあり、 これをそのまま 3 次元に変換すると把持位置が数 mm から 1 cm 程度ずれる。そこで、VLM の点を「物体の識別」に、深度画像を「位置の精密化」に用いる二段構えとした。

まず、深度画像の全画素をカメラの内部パラメータと外部パラメータを用いて世界座標に逆投影する。画素 (u, v) の深度を d、焦点距離を f、画像中心を (c_x, c_y) とすると、 カメラ座標系での点は次式で与えられる。

$$p_{\mathrm{cam}} = \left((u - c_x)\, d / f,\ -(v - c_y)\, d / f,\ -d \right)$$

次に、VLM の点を逆投影した位置から水平距離 5 cm 以内にあり、作業台面より 12 mm 以上高い点を物体の点群として抽出する。 点群の高さの 90 パーセンタイルを物体の上面高さとし、上面から 8 mm 以内の点の重心を把持中心とした。把持方向は、点群を水平面に射影し、 0°〜90° を 3° 刻みで回転させながら外接矩形の面積が最小となる角度として求めた。立方体の場合、この角度に合わせてグリッパを回転させることで、指が面に正対する。 把持高さは上面高さの 1/2（下限 14 mm）とした。

3.4 動作生成

手先（指先中心、ハンド座標系で 105 mm 前方）の目標位置と、鉛直下向きの目標姿勢を与え、減衰最小二乗法（減衰係数 10^{-3}）による逆運動学で関節角を求める。 冗長自由度は、無理のない姿勢へ引き寄せる項を零空間に加えて利用した。手先の軌道は直交座標系で躍度最小の補間を行い、50 Hz で逆運動学を解いて位置制御器に指令する。 把持・配置の前後には高さ 22 cm の安全高度を経由し、アームが作業台上の他の物体に接触しないようにした。 把持の成否はグリッパの開き幅で判定し、完全に閉じた場合は把持失敗として観測からやり直す。

3.5 閉ループによる再計画

直前のステップが失敗と判定された場合、その物体を処理待ちの列の末尾に戻して後で再試行する。 また、全ステップの終了後に改めて画像を取得して計画を立て直し、未処理の物体がなくなった時点で終了とする。 この構成により、途中で片付け済みの物体が作業台に戻されるといった環境の変化にも対応できる。

4. 実験結果

乱数シード 2 の配置で、指示文「机の上を片付けて。食べ物はお皿に、おもちゃは箱にしまってね。」を与えて実行した。 VLM は果物 3 種を食べ物、立方体 3 個をおもちゃと分類し、それぞれ皿とおもちゃ箱に割り当てる計画を生成した（図 1）。 実行の途中、3 個目の物体を配置した直後に、片付け済みのりんごを作業台上へ戻す外乱を加えた。ロボットは残りの物体を処理した後の再計画でこれを検出し、再び皿へ配置した。最終的に 6 物体すべてが指示どおりの容器に収まった（表 2、表 3）。

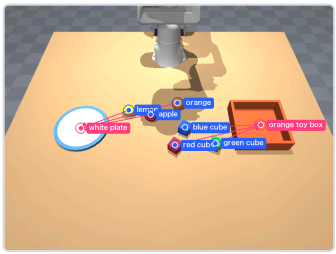


図 1　計画（青: 物体、桃: 行き先、矢印: VLM による割り当て）

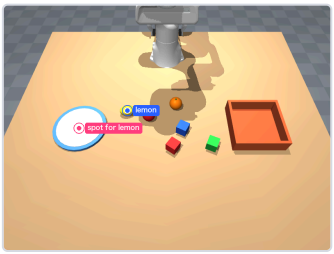


図 2　把持直前の観測（青: 把持対象、桃: 容器内の配置位置）



図 3　直前のステップの成功判定

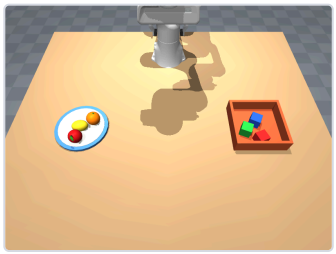


図 4　実行終了時の状態

項目	結果
配置した物体（真値による評価）	6 / 6
実行したステップ数	7（外乱への対応 1 を含む）
成功判定	次ステップ前の確認で成功 5、終了時の再計画で確認 2
把持・配置のやり直し	0 回
再計画の回数	2 回
VLM の呼び出し回数	10 回
動画の長さ（実時間）	123 秒

表 2　実行結果の概要

物体	最終位置（真値）
りんご	お皿
オレンジ	お皿
レモン	お皿
赤い積み木	おもちゃ箱
青い積み木	おもちゃ箱
緑の積み木	おもちゃ箱

表 3　各物体の最終位置

問い合わせ	回数	平均応答時間
plan	3	6.1 秒
locate	7	4.6 秒

表 4　VLM の応答時間

5. 考察

VLM の 2D ポインティングは、本シーンにおいて真値との差が正規化座標で 2/1000 以内（800×600 画像でおよそ 2 画素）であり、物体の識別には十分な精度であった。 一方、把持に必要な 3 次元位置の精度は深度画像

の幾何処理によって確保しており、2D 点に真値を与えて制御系のみを検証した予備実験では、 ランダムな配置 3 通り × 6 物体の計 18 回すべてで把持と運搬に成功した。意味の理解を VLM に、位置の精密化を幾何処理に分担させる設計は、 それぞれの得意分野を活かす点で有効であったと考える。

開発の過程では、物理シミュレーション上の問題がいくつか顕在化した。りんごはヘタと葉の質量によって重心が中心からずれており、外力を加えなくても作業台上を転がっていた。 慣性を球の中心に明示し、果物に転がり摩擦を設定することで解消した。また、待機姿勢から把持直前の姿勢へ関節空間で直接補間すると、アームが作業台の近くを通過して物体を押し出していた。 安全高度を経由する経路に改めることで、この問題も解消した。これらは実機においても、物体の物理特性の把握や経路上の干渉回避として同様に考慮すべき点である。

VLM の応答時間は 1 回あたり平均約 5 秒であり、1 物体の処理に要する時間の中で無視できない割合を占める。 本実装では、API の待ち時間の間はシミュレーションを停止しているため、動画内のロボットの動作は実時間である。 実機で同様の構成をとる場合は、動作中に次の物体の観測を先行して行うなど、推論と動作の並列化が必要になる。

なお、提出動画は、字幕に表示するモデル名を修正するため、本番の実行で記録した VLM の応答を同じ順序で与えて再描画したものである（run_task.py --replay）。 シミュレーションは決定的であるため、動作、判定、最終状態は本番の実行と一致する。記録した応答は、本番での実際の推論結果である。

6. 今後の課題

現在の把持は鉛直上方からのアプローチに限られており、平たい物体や積み重なった物体には対応していない。サンプル [1] で扱われている軌道出力を利用した障害物回避や、把持点を 2 点で指示させることによる把持姿勢の推定を導入すれば、より複雑な片付けへ拡張できると考える。 また、入力は 1 台の RGB-D カメラのみであり、シミュレータの真値に依存しない構成としたため、RealSense 等の深度カメラと実機アームを用いた検証も今後の課題である。

参考文献

1. npaka, 「Gemini Robotics-ER 1.6 を試す」, note, 2026. https://note.com/npaka/n/n93116b196748
2. E. Todorov, T. Erez, Y. Tassa, "MuJoCo: A physics engine for model-based control," IROS, 2012.
3. Google DeepMind, "MuJoCo Menagerie," https://github.com/google-deepmind/mujoco_menagerie
4. Google, "Gemini Robotics-ER," Gemini API Documentation.